Gonzalo Díaz Amor

Data Scientist | Especialista GenAI & MLOps | Ingeniero LLM & RAG

Email | Teléfono | LinkedIn | GitHub | Portfolio

Perfil Profesional

Data Scientist orientado a GenAI con experiencia práctica en el desarrollo de pipelines de ML e IA en Python, construcción de APIs, automatización de flujos de datos y despliegue de modelos en entornos cloud. Especializado en **arquitecturas basadas en LLMs, embeddings, pipelines RAG e ingeniería de prompts**, con exposición práctica a Azure, LangChain y operacionalización de modelos. Competente en Python, R, SQL e ingeniería de datos en la nube, con capacidad demostrada para desarrollar modelos predictivos y optimizar procesos de negocio.

Experiencia Relevante

Ingeniero de Investigación en IA/ML

BeWay | *Jan 2026 – Present*

- Implementé el sistema **LLM-as-a-Judge** (Gu et al., 2025) para el pipeline de auditoría RNA (Reasoning Numerical Alignment), diseñando la arquitectura completa y la taxonomía de evaluación.
- Construí una biblioteca de prompts y un pipeline automatizado que realiza verificaciones de fidelidad, pairwise y ranking holístico sobre los artefactos BOCR (Beneficios, Oportunidades, Costes, Riesgos).
- Integré técnicas de mitigación de sesgos utilizando razonamiento CoT (Chain of Thought), evaluación basada en rúbricas, votación con intercambio de posición) para garantizar juicios robustos y reproducibles.
- Desarrollé scripts de alto rendimiento en Python y R, y herramientas basadas en **AWS** para ejecutar el juez a gran escala en múltiples escenarios.
- *Stack:* Python, R, AWS, Docker, Git, CI/CD

Data Scientist Especialista AI/ML

Daiichi-Sankyo | *Oct 2025 – Dec 2025*

- Trabajé en un **proyecto de Causal AI** que identificó factores ambientales clave entre cientos de variables para cuantificar el efecto causal de la contaminación en miles de resultados de pacientes, usando **Double Machine Learning con Causal Forest**.
- Desarrollé la infraestructura de datos y scripts de alto rendimiento para despliegue en **AWS**.
- Contrato de duración determinada finalizado por reestructuración presupuestaria; salida en excelentes términos con referencias profesionales sólidas.
- *Stack: Python, Google Cloud.*

Data Scientist de Comportamiento

BeWay | *Jun 2025 – Oct 2025*

- Apoyé un **proyecto de Geo Data Science** que identificó las 10 características más relevantes entre cientos de variables para determinar la penetración del producto en más de 60 millones de tickets.

- Lideré un **proyecto de optimización de funnel** usando análisis de supervivencia Kaplan-Meier sobre 10.000+ clientes para identificar barreras de conversión y acelerar el tiempo a la primera compra.
- *Stack: R, Python, Quarto, AWS, PostgreSQL, Git.*

Especialista en Data Science

Minsait | *Nov 2023 – Jun 2025*

- Desarrollé un **data lake** integral integrando diversas fuentes de datos hospitalarios, garantizando precisión y consistencia para la implementación en **OMOP-CDM (OHDSI)**.
- Construí **APIs RESTful para inferencia ML/AI** (FastAPI), habilitando la integración de componentes GenAI como embeddings, búsqueda vectorial y analítica con LLMs.
- Desarrollé y desplegué **modelos NLP/ML en producción** con Python, incluyendo despliegues con Docker y orquestación ETL con **Apache Airflow**.
- Competente en procesos ETL usando WhiteRabbit y Usagi para mapeo e integración de datos.
- *Stack: R, Python, Docker, FastAPI, PowerShell, GitLab, MySQL, PostgreSQL, Spark, Airflow, OHDSI.*

Data Scientist

TFS HealthScience | *Jun 2022 – May 2023*

- Actué como **líder de programación** para un estudio de Fase IV — ahorrando a la empresa **más de 3 años de investigación** siguiendo estándares SDTM y ADaM para el paquete de sumisión a la EMA.
- Apliqué técnicas de Machine Learning (regresión logística con regularización) para optimizar modelos predictivos, logrando una **mejora del 10% en rendimiento**.
- Creé emparejamiento por propensión entre dos tratamientos usando regresión logística regularizada para prevenir el sobreajuste.
- Realicé cálculos de tamaño de muestra y potencia estadística en R, y redacté planes de análisis estadístico e informes para Fases I–IV.
- *Stack: R, SAS, RStudio, Python, CDISC, OHDSI.*

Data Scientist

Animal Data Analytics | *Sep 2020 – Jun 2022*

- Proveí análisis completos y soluciones recomendadas para **más de 5 clientes internacionales** usando SAS y estándares CDISC.
- Apliqué **algoritmos de ML y Deep Learning** en más de 10 proyectos, logrando al menos un 10% de mejora en rendimiento con informes en RMarkdown.
- Supervisé a 1 becario y 1 data scientist en el desarrollo de un modelo de regresión con una **mejora del 7%** en R.
- Realicé **análisis de supervivencia** (Kaplan-Meier, Cox, log-rank) para resultados de tiempo hasta evento.
- *Stack: R, Python, SAS, RMarkdown.*

Educación

- **Máster en Big Data & Data Science** | VIU – Valencia, Remoto (2025)
  - Formación avanzada en procesamiento de datos a gran escala, arquitecturas cloud y sistemas AI/ML.
- **Grado en Estadística** | UVa – Valladolid, España (2020)
  - Sólida base en modelado estadístico, teoría de la probabilidad y métodos cuantitativos.

Educación Adicional Destacada (ver más en LinkedIn):

- **Curso Intensivo de Agentes IA** (Google x Kaggle, 2025): LLMs, frameworks de agentes, orquestación, evaluación y despliegue en producción.
- **6.86x: Machine Learning con Python – De Modelos Lineales a Deep Learning** (MITx, 2021): Modelos lineales, deep learning, aprendizaje por refuerzo y proyectos prácticos en Python.
- **LangChain para Desarrollo con LLMs** (freeCodeCamp, 2023): Arquitectura transformer, embeddings, pipeline de IA generativa e ingeniería de prompts con LangChain.

Certificaciones

- **Curso Intensivo de Agentes IA** — Google x Kaggle *(2025)*
  - Entrenamiento práctico en diseño y despliegue de sistemas de agentes IA con LLMs, herramientas, memoria y componentes de recuperación. Frameworks de agentes, patrones de orquestación, evaluación y despliegue.
- **LangChain para Desarrollo con LLMs** — freeCodeCamp *(2023)*
  - Arquitectura transformer, embeddings, pipeline de proyectos de IA generativa e ingeniería de prompts. LangChain como interfaz estándar para trabajar con distintos LLMs.
- **Certificado de Análisis de Datos de Google** — Google *(2023)*
  - Formación integral en R, SQL, Python y Tableau para análisis y visualización de datos.
- **6.86x: Machine Learning con Python – De Modelos Lineales a Deep Learning** — MITx *(2021)*
  - Introducción profunda que cubre modelos lineales, deep learning y aprendizaje por refuerzo, con proyectos prácticos en Python.
- **Inteligencia Artificial Explicable (XAI)** — DPhi *(2023)*
  - Machine learning interpretable por humanos usando SHAP y LIME para la explicabilidad de modelos.
- **Análisis de Imágenes Biomédicas en Python** — DataCamp *(2023)*
  - Deep learning para identificación a partir de imágenes médicas con técnicas de aprendizaje supervisado y no supervisado.
- **Bootcamp Online de Deep Learning** — DPhi *(2021)*
  - Bootcamp de reconocimiento de imágenes. Finalicé en el top 20% de la competición final con más del 80% de precisión.
- **Visual Studio Code para R en Farma** — R in Pharma *(2023)*
  - Introducción a VS Code para proyectos de análisis de datos y machine learning en el contexto farmacéutico.
- **Análisis de Datos con Python** — freeCodeCamp *(2023)*
  - Fundamentos del análisis de datos con Python: Pandas, NumPy, Matplotlib y limpieza de datos.
- **Aprendizaje Continuo en Data Science** — Various platforms (see LinkedIn) *(2020 – Present)*
  - Desarrollo profesional continuo en múltiples plataformas. Lista completa disponible en LinkedIn.

Habilidades Técnicas

- **Lenguajes de Programación:** Python (LLM APIs, LangChain, FastAPI), R, SQL, PowerShell.

- **GenAI & LLMs:** Pipelines RAG, embeddings, búsqueda vectorial, ingeniería de prompts, LangChain, arquitecturas basadas en LLMs.
- **ML & Data Science:** Scikit-Learn, Pandas, NumPy, ML Causal (Causal Forest, Double ML), análisis de supervivencia, modelado predictivo.
- **MLOps & Cloud:** Docker, Apache Airflow, AWS, Azure, GCP, Databricks, PySpark, Hadoop.
- **Ingeniería de Datos:** Pipelines ETL, FastAPI, OMOP-CDM (OHDSI), WhiteRabbit, Usagi, estándares CDISC.
- **Bases de Datos & BI:** MySQL, PostgreSQL, MongoDB, Cassandra, PowerBI, Tableau.
- **Control de Versiones & Colaboración:** Git, GitHub, GitLab.
- **Idiomas:** Español (Nativo), Inglés (Avanzado).

Palencia, España | Disponibilidad para relocalización/remoto.