Gonzalo Díaz Amor

Data Scientist | Especialista GenAI & MLOps | Ingeniero LLM & RAG

Email | Teléfono | LinkedIn | GitHub | Portfolio

Resumen Profesional

Data Scientist con más de 5 años de experiencia end-to-end en todo el ciclo de vida del ML — desde modelado estadístico e inferencia causal hasta arquitecturas basadas en LLMs, pipelines RAG y MLOps. Trayectoria en pharma, healthtech y movilidad, con despliegues en producción sobre AWS, GCP y Azure. Actualmente diseño y escalo un sistema empresarial LLM-as-a-Judge, incluyendo diseño de arquitectura, estrategias de mitigación de sesgos y pipelines automatizados de auditoría BOCR. Capacidad demostrada para entregar en entornos de alta velocidad: construcción de data lakes integrando fuentes hospitalarias múltiples, servicios de inferencia ML con FastAPI, y liderazgo de programación clínica para paquetes de submission ante la EMA. Cómodo tanto liderando un pipeline completo de forma autónoma como colaborando transversalmente con equipos de investigación e ingeniería.

Experiencia Relevante

Ingeniero de Investigación en IA/ML

BeWay | *Jan 2026 – Present*

- Lideré el diseño y despliegue del sistema LLM-as-a-Judge para el pipeline de auditoría RNA, definiendo la taxonomía de evaluación y los flujos de puntuación multiescenario.
- Escalé verificaciones automatizadas de fidelidad, pairwise y ranking holístico sobre artefactos BOCR para mejorar la consistencia de revisión y reducir la validación manual.
- Construí herramientas reutilizables en Python/R y orquestación en AWS para ejecutar evaluaciones a gran escala en múltiples variantes de modelo y prompt.
- *Tech stack:* Python, R, AWS, Docker, Git, CI/CD.

Data Scientist de Comportamiento

BeWay | *Jun 2025 – Oct 2025*

- Lideré análisis de Geo Data Science sobre cientos de variables para medir la penetración del producto en más de 60M de tickets e informar decisiones estratégicas.
- Gestioné análisis de supervivencia y funnel en más de 10k clientes para identificar barreras de conversión y acelerar el tiempo hasta la primera compra.
- Transición al rol actual de investigación de IA tras cuatro meses de entrega cross-funcional para escalar sistemas avanzados LLM y RAG.
- *Tech stack:* R, Python, Quarto, AWS, PostgreSQL, Git.

Data Scientist Especialista AI/ML

Daiichi-Sankyo | *Oct 2025 – Dec 2025*

- Entregué un compromiso de Causal AI de 3 meses identificando impulsores ambientales entre cientos de variables para resultados de pacientes con Double ML y Causal Forest.
- Construí la infraestructura de datos y scripts analíticos de alto rendimiento para despliegue en AWS.

- Contrato de duración determinada finalizado por reestructuración presupuestaria; salida en excelentes términos con referencias profesionales sólidas.
- *Tech stack:* Python, Google Cloud.

Especialista en Data Science

Minsait | *Nov 2023 – Jun 2025*

- Construí un data lake OMOP-CDM empresarial integrando fuentes hospitalarias clínicas y operativas para preparación de análisis.
- Gestioné APIs RESTful de inferencia ML/AI con FastAPI, habilitando embeddings, búsqueda vectorial y analítica LLM para aplicaciones downstream.
- Desplegué modelos NLP/ML en producción con Docker y Airflow, estandarizando flujos de trabajo end-to-end y reduciendo handoffs manuales.
- *Tech stack:* R, Python, Docker, FastAPI, PowerShell, GitLab, MySQL, PostgreSQL, Spark, Airflow, OHDSI.

Data Scientist

TFS HealthScience | *Jun 2022 – May 2023*

- Actué como líder de programación para un estudio de Fase IV, validando workflows SDTM y ADaM y ahorrando al equipo más de 3 años de trabajo.
- Desarrollé modelos de regresión logística regularizada para mejorar el rendimiento predictivo y apoyar la sumisión regulatoria.
- Entregué análisis comparativos por emparejamiento de propensión y planes estadísticos listos para regulación.
- *Tech stack:* R, SAS, Python, CDISC, OHDSI.

Data Scientist

Animal Data Analytics | *Sep 2020 – Jun 2022*

- Entregué soluciones de analítica y ML para más de 5 clientes internacionales en compromisos clínicos y comerciales.
- Lideré un pequeño equipo para construir un modelo de regresión que mejoró el rendimiento predictivo en un 7% y traduje resultados en informes RMarkdown.
- Apliqué métodos de análisis de supervivencia a resultados de tiempo hasta evento y presenté insights accionables a stakeholders.
- *Tech stack:* R, Python, SAS, RMarkdown.

Educación

- **Máster en Big Data & Data Science** | VIU – Valencia, Remoto (2025)
  - Formación avanzada en procesamiento de datos a gran escala, arquitecturas cloud y sistemas AI/ML.
- **Grado en Estadística** | UVa – Valladolid, España (2020)
  - Sólida base en modelado estadístico, teoría de la probabilidad y métodos cuantitativos.

Educación Adicional Destacada (ver más en LinkedIn):

- **Inteligencia Artificial Explicable (XAI)** | DPHi (2023)
- **Análisis de Imágenes Biomédicas en Python** | DataCamp (2023)
- **Bootcamp Online de Deep Learning** | DPHi (2021)
- **Visual Studio Code para R en Farma** | R in Pharma (2023)
- **Análisis de Datos con Python** | freeCodeCamp (2023)
- **Aprendizaje Continuo en Data Science** | Varias plataformas

---

Certificaciones

- **Curso Intensivo de Agentes IA** — Google x Kaggle *(2025)*
  - Entrenamiento práctico en diseño y despliegue de sistemas de agentes IA con LLMs, herramientas, memoria y recuperación.
- **6.86x: Machine Learning con Python – De Modelos Lineales a Deep Learning** — MITx *(2021)*
  - Profundización en modelos lineales, deep learning y aprendizaje por refuerzo con proyectos prácticos en Python.
- **LangChain para Desarrollo con LLMs** — freeCodeCamp *(2023)*
  - Desarrollo práctico de LLMs con embeddings, prompts, búsqueda vectorial y orquestación de flujos generativos.
- **Certificado de Análisis de Datos de Google** — Google *(2023)*
  - Formación de analítica en R, SQL, Python y visualización.

Habilidades Técnicas

- **Lenguajes de Programación:** Python (LLM APIs, LangChain, FastAPI), R, SQL, PowerShell.
- **GenAI & LLMs:** Pipelines RAG, embeddings, búsqueda vectorial, ingeniería de prompts, LangChain, arquitecturas basadas en LLMs.
- **ML & Data Science:** Scikit-Learn, Pandas, NumPy, ML Causal (Causal Forest, Double ML), análisis de supervivencia, modelado predictivo.
- **MLOps & Cloud:** Docker, Apache Airflow, AWS, Azure, GCP, Databricks, PySpark, Hadoop.
- **Ingeniería de Datos:** Pipelines ETL, FastAPI, OMOP-CDM (OHDSI), WhiteRabbit, Usagi, estándares CDISC.
- **Bases de Datos & BI:** MySQL, PostgreSQL, MongoDB, Cassandra, PowerBI, Tableau.
- **Control de Versiones & Colaboración:** Git, GitHub, GitLab.
- **Idiomas:** Español (Nativo), Inglés (Avanzado).

Referencias y cartas de recomendación disponibles bajo petición.